Taller RL Trader 2 — DQN y A3C para trading con un único activo

Máster MIAX · Aprendizaje por Refuerzo · Grupo: Albert Martin y Jesús Bussión · Código y notebook reproducibles: *rl_trading/*, *experiments/*, *solucion_taller_trader2.ipynb*

1. Planteamiento: decisiones de diseño y por qué

Entorno	Sin modificar: estado (tendencia de 6 precios, posición), vender/mantener/comprar, recompensa = rendimiento invertido − 0.1% por operación. Simulador vectorizado verificado idéntico al entorno.
Entrada a la red	Tendencia/σ y posición, **sin discretizar**; σ solo de series de entrenamiento (0.025 en GBM, 0.15 en ciclo). Sin escalar, la tendencia varía ~40 veces menos que la posición y la red apenas la distingue. Es biyectiva: no cambia el MDP.
Último paso; ×100	El entorno lo marca *terminated*; decidimos tratarlo como *límite de tiempo* (*bootstrap*): la serie no acaba por nada observable y el estado no contiene t. Sin *bootstrap*, DQN: no concluyente en 3 mercados, equivalente en 1 mercado (Tabla 6). Recompensa ×100: Q en O(1), mismo argmax.
DQN	Red 2-64-64-3; *replay* 50k (transiciones consecutivas correlacionadas); red objetivo (*target* fijo durante C pasos); Double (max sobre Q ruidosas sobreestima «estar dentro»); Huber y recorte de gradiente; $\varepsilon_k=\max(0.02, \lambda_\varepsilon^{\,k})$ por episodio.
A3C	Real: 4 procesos asíncronos (Hogwild, Adam compartido), red actor/crítico de dos cabezas como la del profesor, ventaja a n pasos y entropía β. *On-policy*, sin *replay*: decorrelan los workers, cada uno en series distintas.
Referencias	Aleatorio, B&H, siempre fuera, momentum/contraria, oráculo miope* (invierte si $E[r_{t+1}\mid\text{tendencia}]>0$), Q-learning tabular, **mejor regla de umbrales** (búsqueda exhaustiva de 1–4 umbrales en entrenamiento) y **oráculo oculto** (conoce fase, equilibrio o régimen: techo).
Protocolo	Semillas disjuntas: entrenamiento (serie nueva por episodio), validación (40 series: ajuste y parada temprana), test (100 series comunes: pareado). Ajuste aleatorio (12/10/12 config. DQN/A3C/Q-learning; Tabla 2), 5 semillas nuevas. El test no elige nada.
Métricas	Σr = recompensa total, lo que optimiza el agente (principal); log-riqueza (del balance) y **cociente de capital** exp(Δ log-riqueza), lo que le importa al inversor: Σr suma rendimientos aritméticos («G sube pero el PnL no»).
Estadística	**Regla única** para los 252 contrastes: Wilcoxon pareado sobre 100 series con la media de las semillas en cada serie (inferencia sobre estos modelos) + IC95% *bootstrap* jerárquico (remuestrea semillas y series: añade la variabilidad entre entrenamientos). **Gana/pierde**: p ajustada <0.05 y el IC excluye el 0; **equivalente**: IC90% dentro de ±δ (TOST); si no, **no concluyente**. δ = 0.02 de Σr (0.12 en el ciclo, 2% del B&H). **Confirmatoria**: los mínimos (20, Holm); **exploratoria**: el resto (232, Benjamini-Hochberg). Friedman-Nemenyi y potencia.

Tabla 1. Decisiones de diseño y su justificación. vol./MA = volatilidad de 20 días y P/MA30−1; ventana = 10 últimos log-rendimientos (causales, verificado).

¿Qué se puede aprender? $E[r_{t+1}\mid\text{decil de tendencia}]$ en 400 series de entrenamiento: ciclo, *momentum* (-20‰ a +45‰); GBM, nada ($|E| \le 0.25‰ <$ comisión de 1‰); reversión, *contraria* (+2.6‰ a -1.2‰); regímenes, **U invertida** (+0.35‰ en el centro, -1.6‰ en el extremo: la tendencia extrema delata el régimen bajista). Es la estrategia esperada (Fig. 1).

Hiperparámetros	Tendencia+ciclo	Browniano (GBM)	Reversión media	Regímenes
DQN (400 ep)	α=0.0003, γ=0.5, λ_ε=0.95, C=1000	α=0.001, γ=0.9, λ_ε=0.99, C=1000	α=0.001, γ=0.5, λ_ε=0.95, C=250	α=0.0003, γ=0.5, λ_ε=0.98, C=1000
A3C (1200 ep, 4 w)	α=0.0003, γ=0.5, β=0.001, n=20	α=0.0003, γ=0.99, β=0.05, n=5	α=0.0001, γ=0.99, β=0.05, n=20	α=0.0001, γ=0.5, β=0.001, n=20
Q-learn. (2000 ep)	α_0=0.05, γ=0.9, λ_ε=0.99, bins=10	α_0=0.1, γ=0.9, λ_ε=0.995, bins=16	α_0=0.05, γ=0.99, λ_ε=0.995, bins=16	α_0=0.05, γ=0.99, λ_ε=0.995, bins=16

Tabla 2. Hiperparámetros elegidos en validación. γ=0.5 gana en 5 de 8 casos DQN/A3C: la señal predice el paso siguiente y un horizonte corto reduce la varianza del *target*.

2. Resultados de los mínimos (test: 100 series × 5 semillas)

Agente	Tendencia+ciclo			Browniano (GBM)			Reversión media			Regímenes		
	Ret.med %	Σr	>B&H %	Ret.med %	Σr	>B&H %	Ret.med %	Σr	>B&H %	Ret.med %	Σr	>B&H %
Aleatorio	+984.2	+2.861	6	-13.3	-0.155	31	-13.5	-0.113	0	-19.3	-0.222	33
Buy & Hold	3,634	+6.014	0	-0.8	**+0.014**	0	-0.4	+0.105	0	-12.5	-0.110	0
Siempre fuera	+0.0	+0.000	10	+0.0	+0.000	51	+0.0	+0.000	53	+0.0	+0.000	71
Momentum	39,653	+7.505	94	-20.7	-0.119	35	-27.9	-0.269	7	-20.5	-0.154	48
Contraria	-95.0	-1.675	0	-14.7	-0.104	47	+8.6	+0.122	62	-18.3	-0.190	49
Oráculo miope*	29,233	+7.773	97	-25.3	-0.251	27	+3.9	+0.100	56	-19.6	-0.160	48
Q-learning	37,656	**+7.989±0.16**	99	-8.0	-0.043±0.03	46	+27.0	+0.271±0.04	95	+4.5	**+0.077±0.00**	79
DQN	29,311	+7.902±0.06	99	-0.4	+0.013±0.00	43	+24.3	**+0.282±0.02**	96	-0.5	+0.040±0.02	81
A3C	33,255	+7.638±0.91	99	-4.1	-0.006±0.03	47	+14.7	+0.224±0.02	84	+0.0	+0.000±0.00	71

Tabla 3. Ret.med = rendimiento final mediano; Σr = recompensa total media (±sd entre semillas); >B&H = % de series cuya riqueza final supera a B&H. Negrita: mejor Σr.

Convergencia	Tendencia+ciclo	Browniano (GBM)	Reversión media	Regímenes
Q-learning	880 ep ≈ 21 s / 47 s	265 ep ≈ 3 s / 24 s	1250 ep ≈ 15 s / 24 s	885 ep ≈ 11 s / 25 s
DQN	188 ep ≈ 95 s / 203 s	128 ep ≈ 55 s / 173 s	236 ep ≈ 102 s / 172 s	106 ep ≈ 42 s / 159 s
A3C	224 ep ≈ 7 s / 37 s	40 ep ≈ 2 s / 55 s	920 ep ≈ 13 s / 17 s	80 ep ≈ 1 s / 17 s

Tabla 4. Episodios hasta el 90% de la mejora en validación (media de 5 semillas) ≈ segundos hasta ese punto / tiempo total, **sin carga** y en serie (1 semilla). Un episodio de DQN cuesta ≈31 de Q-learning, pero converge en 106–236 episodios frente a 265–1250; en segundos gana A3C. DQN y Q-learning son deterministas; A3C no.

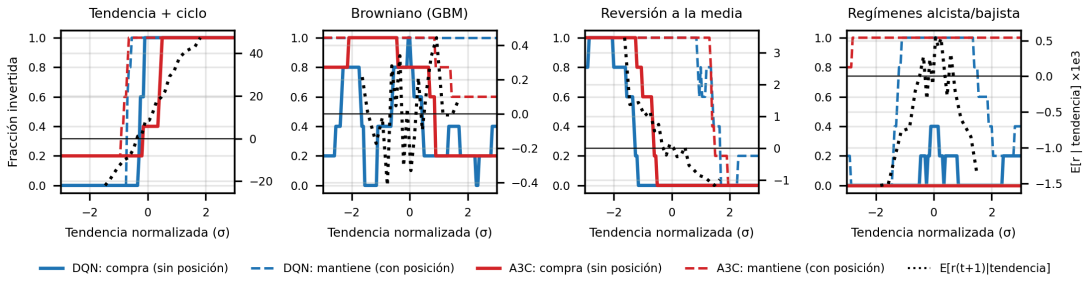


Figura 1. Política greedy aprendida (fracción de semillas invertidas; continua: compra sin posición; discontinua: mantiene con posición) frente a $E[r_{t+1}\mid\text{tendencia}]$ (punteada).

- **Ciclo** (Tabla 3, Fig. 1)**:** *momentum* con histéresis (compra con tendencia >0 y mantiene aunque baje algo de 0); baten a B&H en el 99% de las series con 30–53 operaciones, frente a 82 del oráculo miope, que ignora la comisión. **GBM:** DQN converge a B&H (1 operación; **equivalente**, IC90% [-0.005, +0.002]): sin señal, operar solo paga comisión; Q-learning sobreopera (47 operaciones).
- **Reversión:** contraria con histéresis: DQN +24.3% mediano (B&H -0.4%) con 25 operaciones frente a 127 de la regla contraria: solo opera en los extremos. **Regímenes:** Q-learning y DQN aprenden la **banda** no lineal esperada (+0.077 y +0.040); A3C se queda en «siempre fuera» (Σr 0.000).

3. Balance: qué batimos y qué no

A frente a B (Δ = Σr de A − Σr de B)	Tendencia+ciclo	Browniano (GBM)	Reversión media	Regímenes
DQN vs Aleatorio[C]	▲ +5.04	▲ +0.168	▲ +0.395	▲ +0.262
A3C vs Aleatorio[C]	▲ +4.78	▲ +0.149	▲ +0.337	▲ +0.222
DQN vs Buy & Hold[C]	▲ +1.89	= -0.001	▲ +0.178	▲ +0.150
A3C vs Buy & Hold[C]	▲ +1.62	· -0.021	▲ +0.119	· +0.110
DQN vs Q-learning[C]	· -0.09	▲ +0.056	· +0.011	▼ -0.037
A3C vs DQN	· -0.26	· -0.019	▼ -0.058	· -0.040
Q-learning vs Buy & Hold	▲ +1.97	▼ -0.057	▲ +0.166	▲ +0.187
DQN vs Mejor regla	▼ -0.22	· +0.007	· +0.005	· +0.024
PPO vs Mejor regla	= -0.04	· -0.001	· +0.012	· -0.016
PPO+ventana+vol./MA vs Mejor regla	▲ +0.57	· +0.007	▲ +0.171	▲ +0.126
DQN vs Oráculo oculto	▼ -3.21	= -0.001	▼ -0.375	▼ -0.184
% del margen hasta el oráculo oculto capturado: DQN → PPO+ventana+vol./MA	37% → 52%	sin margen	32% → 62%	18% → 63%

Tabla 5. Veredicto con la regla única (Tabla 1): ▲ gana, ▼ pierde, = equivalente (TOST), · no concluyente; el número es Δ Σr. [C] = familia confirmatoria (Holm); resto, Benjamini-Hochberg. RL: 5 semillas (PPO+ventana+vol./MA: 3).

- **Batimos** (14 de 20 contrastes confirmatorios): al aleatorio en los 4 mercados con DQN y A3C, y a B&H donde hay señal; DQN multiplica el capital final de B&H por 14.6, 1.26 y 1.22 (ciclo, reversión, regímenes). En GBM, «equivalente a B&H» es lo correcto. A3C frente a B&H en regímenes (+0.110) no resiste a Holm (p_{Holm}=0.11). Friedman rechaza la igualdad de los agentes en los 4 mercados (p≤3e-30; diferencia crítica de Nemenyi 1.51 rangos).
- **DQN frente a Q-learning** (petición del profesor): DQN gana en GBM (+0.056; Q-learning sobreopera) y pierde en regímenes (-0.037, IC [-0.069, -0.006]); en ciclo y reversión es **no concluyente**, no un empate: en reversión el IC90% [-0.025, +0.045] se sale de ±δ. Potencia: el 61–83% de la incertidumbre viene de las semillas; el efecto mínimo detectable en reversión es 0.062 con 5 semillas y 0.038 con 20, aún >δ: separar algoritmos exige más semillas, no más series. Con una variable continua, 10–16 bins equiprobables apenas pierden información: la red no gana en representación, sí en eficiencia muestral (Tabla 4).
- **No batimos** a la **mejor regla de umbrales** en el ciclo (DQN -0.22, IC [-0.36, -0.08]; PPO -0.041, equivalente, y con el doble de episodios +0.011), y nadie alcanza al **oráculo oculto**: DQN captura el 37%, 32% y 18% del margen entre la mejor política trivial y él. Con esta observación, la política óptima *es* una regla de dos umbrales si la ventaja de estar dentro es monótona en la tendencia, y la búsqueda exhaustiva la optimiza directamente; en regímenes la regla de 4 umbrales sobreajusta (0.069 en ajuste, 0.016 en test) y Q-learning la supera (+0.061). **Con más información sí**: PPO + ventana + vol./MA bate a la regla en ciclo, reversión y regímenes, y la captura sube al 52%, 62% y 63%. El cuello de botella es la observación, no el algoritmo.

4. Qué probamos: qué mejoró, qué empeoró y qué no cambió

Qué probamos (A vs B; semillas)	Tendencia+ciclo	Browniano (GBM)	Reversión media	Regímenes
Mejoró (gana en algún mercado y no pierde en ninguno)				
Double DQN vs solo red objetivo (modelo final) (2)	▲ +0.11	· -0.052	· +0.056	· -0.012
Más episodios (ciclo: PPO ×2; reversión: A3C ×2.5; regímenes: DQN ×2.5) (5)	= +0.05	–	▲ +0.054	· +0.020
Parada temprana por validación vs modelo final (DQN) (5)	· -0.08	· +0.029	▲ +0.076	▲ +0.055
Parada temprana por validación vs modelo final (A3C) (5)	· -0.06	▲ +0.089	· -0.018	= +0.000
Ensemble de las 5 semillas vs cada semilla (A3C) (1 vs 5)	· +0.35	▲ +0.027	· +0.006	= +0.000
PPO (GAE + objetivo recortado) vs DQN (5)	▲ +0.18	· -0.008	· +0.007	· -0.040
Estado + vol./MA vs estado base (A3C) (3)	· +0.77	· -0.010	▲ +0.208	= +0.000
Estado + vol./MA vs estado base (PPO) (3)	· -0.03	· -0.006	▲ +0.157	▲ +0.118
Estado + ventana + vol./MA vs base (PPO) (3)	▲ +0.60	= +0.002	▲ +0.161	▲ +0.141
Recompensa $r-\lambda r^2$, λ=2 (en log-riqueza) (3)	▲ +0.17	= -0.001	· -0.005	▲ +0.065
Depende del mercado (gana en unos y pierde en otros)				
Estado + vol./MA vs estado base (DQN) (5)	▲ +0.22	▼ -0.058	▲ +0.095	▲ +0.069
Estado + ventana de 10 rendimientos vs base (DQN) (5)	▲ +0.28	▼ -0.108	▼ -0.194	· +0.008
Un DQN para los 4 mercados (+vol./MA) vs especializado (5)	· -0.30	· +0.002	▲ +0.118	▼ -0.095
Recompensa $r-\lambda r^2$, λ=10 (en log-riqueza) (3)	▼ -5.52	= +0.000	· -0.007	▲ +0.047
Sin cambio demostrable (equivalente o no concluyente)				
Quitar la red objetivo (vanilla vs Double, modelo final) (2)	· -0.04	· +0.033	· -0.059	· +0.001
Dueling DQN vs DQN (5)	= -0.03	· -0.006	· +0.012	· +0.009
Último paso terminal, sin *bootstrap* (DQN) (3 vs 5)	= -0.02	· -0.016	· -0.008	· -0.002
DQN con γ=0 vs γ=0.5 (2)	· -0.03	= +0.001	· +0.009	· -0.033
DQN con γ=0.99 vs γ=0.5 (2)	· -0.08	= -0.008	· -0.008	· -0.007
Ensemble de las 5 semillas vs cada semilla (DQN) (1 vs 5)	= +0.04	= -0.001	· -0.026	· -0.040
Recompensa $\log(B_t/B_{t-1})$ (en log-riqueza) (3)	· +0.05	· +0.001	· +0.017	· +0.014
Empeoró (pierde en algún mercado y no gana en ninguno)				
DQN con γ=0.9 vs γ=0.5 (2)	▼ -0.13	= +0.000	· +0.002	· -0.082
Expected SARSA (on-policy) vs Q-learning, misma tabla (3)	· +0.00	–	–	▼ -0.076
Robustez a la comisión (DQN y regla re-entrenados con otra comisión)				
Comisión 0%: DQN vs regla re-ajustada (3 vs regla)	▼ -0.23	–	· -0.018	· -0.036
Comisión 0.5%: DQN vs regla re-ajustada (3 vs regla)	· -0.04	–	· -0.032	▲ +0.103

Tabla 6. Cada experimento (A) frente a lo que sustituye (B), con la misma regla (Δ Σr; log-riqueza en las filas de recompensa); entre paréntesis, semillas: con 2–3, ▲ y = son indicios (el IC jerárquico estima mal la variabilidad entre entrenamientos). Parada temprana, ensemble, oráculo oculto y cociente de capital son ideas de otros trabajos, recalculadas con nuestro protocolo.

- **Mejoró.** La **parada temprana** rescata lo aprendido antes de que la política derive (DQN +0.076 en reversión y +0.055 en regímenes). El **ensemble** de A3C anula la semilla que colapsó a «siempre dentro» (ciclo +0.35, no concluyente por esa misma semilla). **PPO** reutiliza cada lote con el objetivo recortado: es el más estable y supera a DQN en el ciclo. **Más información en el estado** ayuda a los tres algoritmos profundos donde hay estructura oculta. Con **λ=2** la penalización castiga más el régimen bajista (más volátil): actúa como filtro de régimen (log-riqueza +0.065; exposición 63% → 44%, *drawdown* 28% → 20%).
- **Depende del mercado.** Más variables hacen que DQN **sobreopere donde no hay señal**: con la ventana, 111 operaciones en reversión, y triplicar los episodios no lo corrige (-0.152). Un único agente para los 4 mercados mejora en reversión y pierde en regímenes: con vol./MA distingue el mercado, pero no del todo. Con **λ=10**, en el ciclo (≈10% de volatilidad por paso) la penalización supera a la señal y el agente sale del mercado (*drawdown* 71% → 11%): λ debería escalarse con la varianza de cada mercado.
- **Sin cambio demostrable.** Sin red objetivo la validación final cae en reversión (0.107 frente a 0.273), pero en test, con 2 semillas, es no concluyente (-0.059, IC [-0.147, +0.023]): indicio, no prueba. Dueling: equivalente en 1 mercado y no concluyente en el resto (con 3 acciones separar V y A apenas aporta). Ningún γ mejora a 0.5 (γ=0.9 empeora el ciclo). $\log(B_t/B_{t-1}) \approx r - r^2/2$ (salvo al operar: la comisión es multiplicativa) equivale a λ≈0.5. El ensemble de DQN en regímenes promedia bandas distintas y acaba «siempre fuera» (-0.040): promediar valores no promedia políticas.
- **Empeoró: *on-policy* con señal débil.** A3C y PPO acaban «siempre fuera» en regímenes. Sin entropía, la política estocástica de PPO pasa de estar invertida el 40% del tiempo al 0.00%; con entropía 0.2 sigue explorando (47%) y tampoco aprende (-0.010); A3C con 3000 episodios y la configuración elegida en validación, tampoco (+0.013). Evidencia a favor (no aísla todas las diferencias con A3C y PPO): con la misma tabla, cambiar solo el objetivo de Q-learning (max, *off-policy*) por Expected SARSA (*on-policy*) hunde el resultado (-0.076, IC [-0.116, -0.038]; con ε=0.3, -0.017, no concluyente). On-policy valora «comprar» bajo su propia exploración, que paga comisiones al deshacer la posición (*cliff walking*): con una ventaja (≈0.4‰) menor que el coste de explorar, «fuera» es un óptimo local.
- **Comisión.** Con más comisión DQN opera menos (reversión 57 → 7 operaciones) y ensancha la zona de no operar (2.0σ → 4.2σ), como predicen los modelos con costes proporcionales; sin comisión la histéresis no desaparece (la posición hace de memoria en una observación no markoviana). Al 0.5%, DQN supera en regímenes a la regla re-ajustada, que sobreajusta.
- **Otras pruebas** (sin contraste por serie): A3C escala ×5.5 con 16 workers en el ciclo (sin el arranque de procesos); las políticas no generalizan entre mercados (exceso de log-riqueza sobre B&H +0.78 en su mercado, -0.65 fuera); en el S&P 500 de 2011 (una serie, fuera de muestra) DQN gana +12.8% frente a -1.1% de B&H, pero frente a 20 000 estrategias aleatorias de igual exposición y nº de operaciones solo 1 de 9 ejecuciones es significativa tras Benjamini-Hochberg: indicio, no evidencia.

5. Conclusiones y limitaciones

(1) DQN **redescubre la estrategia esperada** en los 4 mercados, con la histéresis que impone la comisión; A3C, en ciclo y reversión (en regímenes se queda fuera). Ambos baten al aleatorio y a B&H donde hay señal. En GBM, DQN converge a B&H (1 operación), mientras A3C (18) y Q-learning (47) operan ruido. (2) Con la observación del enunciado no superan a la mejor regla de dos umbrales (DQN pierde en el ciclo, PPO es equivalente) salvo en regímenes, donde la regla sobreajusta, y quedan lejos del oráculo oculto: el límite es la **observación**; con volatilidad y media móvil el RL profundo supera a la regla y la red aventaja a la tabla. (3) Con señal débil (regímenes) los métodos **on-policy** colapsan a «siempre fuera»; Q-learning y DQN no. (4) La **metodología** cambia las conclusiones: parada temprana, semillas, test pareado, corrección múltiple y TOST convierten «DQN empata con Q-learning» en «no concluyente con 5 semillas». **Limitaciones:** datos sintéticos estacionarios; comisión sin deslizamiento; búsqueda de hiperparámetros limitada; las variantes de las Tablas 5–6 heredan los hiperparámetros del estado base y usan 2–5 semillas (poca potencia para efectos pequeños); el S&P 500 es una sola serie. Descartados por coste/beneficio: REINFORCE y A2C síncrono (PPO y A3C los cubren), MSE frente a Huber, más mercados sintéticos y otros activos reales.